

Carga, Lectura y Manipulación de Datos mediante Pandas en Python

Alumno:

Héctor Iván Orellana Iraheta

ESI School of Management – Big Data with Python

Mgts. Juan Quintanilla

Fecha de entrega: 23/08/2026

INTRODUCCIÓN

La gestión y análisis de datos constituye una de las actividades fundamentales dentro del ámbito de Big Data y la analítica de información. En este contexto, Python se ha consolidado como uno de los lenguajes más utilizados para el procesamiento de datos debido a su flexibilidad y a la amplia disponibilidad de librerías especializadas. Entre ellas destaca Pandas, una herramienta que permite realizar tareas de carga, transformación, limpieza y análisis de datos de manera eficiente.

El presente ejercicio tiene como finalidad aplicar los conocimientos adquiridos sobre la manipulación de archivos mediante Python, utilizando una base de datos académica almacenada en formato Excel. A través de la librería Pandas se realizó la carga del documento, la lectura de la información, la validación de la calidad de los datos y la generación de un nuevo archivo procesado.


DESARROLLO DE LA ACTIVIDAD

1. Carga del Documento

Para iniciar el proceso se utilizó la librería Pandas con el objetivo de importar la base de datos denominada Base_Estudiantes.xlsx.

El archivo fue cargado mediante la función read_excel(), la cual permite leer archivos de Microsoft Excel y convertirlos en una estructura DataFrame para su posterior análisis.

Para ello utilizamos el código.



```
File Edit Selection View Go Run Terminal Help
actividad_estudiantes.py X
C: > Users > hecto > Downloads > actividad_estudiantes.py > ...
1 import pandas as pd
2
3 archivo = r"C:\Users\hecto\Downloads\Base_Estudiantes.xlsx"
4
5 df = pd.read_excel(archivo)
6
```

La ejecución del código permitió visualizar los primeros registros de la base de datos, confirmando que la información fue importada correctamente.

PS C:\Users\hecto\AppData\Local\Programs\Microsoft VS Code> & C:\Users\hecto\AppData\Local\Python\pythoncore-3.14-64\python.exe c:/Users/hecto/Downloads/actividad_estudiantes.py

Número	Curso	Alumnos	Evaluación 1	Evaluación 2	Evaluación 3	Evaluación 4	Evaluación 5	Promedio	Estado
0	1 560-35 Big Data with Python	Alvarenga Siliezar Alvarenga Siliezar	77.0	78.0	63.0	79.0	81.0	75.6	Aprobado
1	2 560-35 Big Data with Python	Layton Miranda Layton Miranda	91.0	62.0	53.0	83.0	75.0	72.8	Aprobado
2	3 560-35 Big Data with Python	Martínez Donado Martínez Donado	82.0	86.0	63.0	NaN	92.0	79.8	Aprobado
3	4 560-35 Big Data with Python	Guerra Artiga Guerra Artiga	90.0	NaN	94.0	65.0	75.0	78.6	Aprobado
4	5 560-35 Big Data with Python	Canel García Canel García	69.0	66.0	58.0	54.0	NaN	61.8	Reprobado

2. Lectura y Creación de Archivo

Posteriormente se procedió a analizar la estructura general de la base de datos para conocer la cantidad de registros, columnas y tipos de datos almacenados.

Resultados obtenidos

La base de datos contiene:


- 107 registros.
- 10 columnas.
- Información numérica y categórica.

Estructura identificada

Campo	Tipo de dato
Número	Integer
Curso	String
Alumnos	String
Evaluación 1	Float
Evaluación 2	Float
Evaluación 3	Float
Evaluación 4	Float
Evaluación 5	Float
Promedio	Float
Estado	String

El análisis permitió verificar que los datos fueron interpretados correctamente por Pandas, garantizando la consistencia necesaria para realizar procesos posteriores de limpieza y transformación.

Finalmente, se generó una nueva versión del archivo utilizando la función:




```
File Edit Selection View Go Run Terminal Help
actividad_estudiantes.py X
C: > Users > hecto > Downloads > actividad_estudiantes.py > ...
19     )
20
21     print("\nArchivo limpio creado correctamente.")
22     promedio_general = df["Promedio"].mean()
```

Lo anterior permitió crear un nuevo archivo Excel con la información procesada.

3. Manipulación y Limpieza de Datos

Como parte del proceso de preparación de datos se ejecutaron diferentes validaciones para identificar posibles problemas de calidad de la información.

Validación de Valores Nulos



```
File Edit Selection View Go Run Terminal Help
actividad_estudiantes.py X
C: > Users > hecto > Downloads > actividad_estudiantes.py > ...
6
7     print(df.head())
8     print("\nInformación de la base:")
9     print(df.info())
10    print("\nValores nulos:")
11    print(df.isnull().sum())
12    duplicados = df.duplicated().sum()
13
```

```

PROBLEMS  OUTPUT  DEBUG CONSOLE  TERMINAL  PORTS

Valores nulos:
Número      0
Curso       0
Alumnos     0
Evaluación 1  6
Evaluación 2 10
Evaluación 3  7
Evaluación 4  6
Evaluación 5  9
Promedio    4
Estado      0
dtype: int64

```

Análisis

Se identificó la existencia de valores faltantes principalmente en las evaluaciones académicas y en algunos registros de promedio.

Estos datos incompletos pueden afectar análisis posteriores y evidencian la importancia de realizar procesos de limpieza y validación antes de utilizar la información para la toma de decisiones.

Validación de Registros Duplicados

Para identificar posibles duplicidades se ejecutó:

```

File  Edit  Selection  View  Go  Run  Terminal  Help

actividad_estudiantes.py X
C: > Users > hecto > Downloads > actividad_estudiantes.py > ...
14 print("\nRegistros duplicados:")
15 print(duplicados)
16 df.to_excel(
17     "Base_Estudiantes_Limpia.xlsx",
18     index=False
19 )

```

```
PROBLEMS  OUTPUT  DEBUG CONSOLE  TERMINAL  PORTS

dtype: int64

Registros duplicados:
0
```

Análisis

La base de datos no presenta registros repetidos, lo cual indica una adecuada integridad de la información almacenada.

Análisis Estadístico Básico

Como parte del ejercicio se realizó un análisis descriptivo de los datos académicos.

Promedio General

```
File  Edit  Selection  View  Go  Run  Terminal  Help

actividad_estudiantes.py X

C: > Users > hecto > Downloads > actividad_estudiantes.py > ...
22  promedio_general = df["Promedio"].mean()
23
24  print("\nPromedio general del curso:")
25  print(round(promedio_general, 2))
26  print("\nEstado de estudiantes:")
27  print(df["Estado"].value_counts())
28  import pandas as pd
```

```
PROBLEMS  OUTPUT  DEBUG CONSOLE  TERMINAL  PORTS

Promedio general del curso:
76.13
```

Este valor indica que el rendimiento promedio de los estudiantes se encuentra en un nivel satisfactorio.

Distribución de Estados Académicos

```
PROBLEMS  OUTPUT  DEBUG CONSOLE  TERMINAL  PORTS

Estado de estudiantes:
Estado
Aprobado    94
Reprobado   13
Name: count, dtype: int64
```

Análisis

El 87.85% de los estudiantes aprobaron el curso, mientras que únicamente el 12.15% obtuvieron una calificación insuficiente.

Estos resultados evidencian un desempeño académico favorable dentro de la población analizada.

CONCLUSIONES

La utilización de la librería Pandas permitió realizar de manera eficiente la carga, lectura y manipulación de la base de datos académica.

Durante el proceso se identificó que la información presenta valores nulos en algunas evaluaciones, situación que debe considerarse en futuros análisis para evitar sesgos en los resultados. Asimismo, se comprobó que no existen registros duplicados, lo que demuestra una adecuada consistencia de la información.

El análisis estadístico permitió determinar un promedio general de 76.13 puntos y una tasa de aprobación cercana al 88%, indicadores que reflejan un desempeño positivo de los estudiantes registrados en la base de datos.

Finalmente, el ejercicio permitió fortalecer competencias relacionadas con la preparación y análisis de datos utilizando Python, una habilidad fundamental en proyectos de Big Data y Ciencia de Datos.

Referencias

McKinney, W. (2022). *Python for Data Analysis* (3rd ed.). O'Reilly Media.

Pandas Development Team. (2024). *Pandas Documentation*. <https://pandas.pydata.org>

Camp BI. (s.f.). *Carga de datos en pandas* [Video]. YouTube. <https://youtu.be/pRGes-EKxUs?si=po9KD6m1D6g8I1bP>